

Apodex 融合对照简报

两边保留的能力，以及三个 harness 的测题分数

2026年9月4日

融合是 **Research Pi 底座 + 嵌进去的科学小板块**，不是另开评测环。交 TRACE 仍是一个 agent。
RESEARCH_PI_SCIENCE=0 只对照师兄原版。下面分数来自 executable-world 五题、apodex-1.1、seed 0。

简称	是什么
Harness	本仓库 apodex_harness.solve，策略层直接驱 EW
原版 Pi	师兄 Apodex-Pi，科学扩展关闭
融合 Pi	同一 Pi，打开 scientific-loop、科学工具、交卷对齐

原版 Pi 保留了什么

研究合同没有拆掉。只有当前观察是隐藏世界、类型化动作、仪器读数、或必须写出指定结果文件时，才启用科学条款。

能力	落点
假设、证据、Project memory、Codex	APPEND_SYSTEM.md 其余各节；record_experiment 只记改变判断的结果
Leader / Analysis 与 mailbox	Research Runtime；print 评测可接管 Leader
证据与工作分离	跑通命令或写出文件只证明做了工，不是科学证据
按 brief 逐步探测、嵌套交卷	采购题 ep.act("submit", {"plan": ...})，这是原版 0.96 的来源
对照开关	RESEARCH_PI_SCIENCE=0 关掉科学扩展

TPM 间隔、滚动 token 窗、429/断线重试是为了让两边都能跑完，不是科学策略。

Harness 嵌进去的能力

只加换题、换 seed 仍成立的条款，落在同一个 scientific-loop，不是第二个 agent。

能力	落点
便宜探针、分叉、错了改调用	scientific-loop: Spend, split, recover
镜像副本、永不重复的生成器、陈述的垃圾上限硬门、未核字段须核查或声明	合同科学节 + skill
交卷跟 brief 走	submit(plan/finding/strategy) 必须包一层；摊平或改名当成空提交
预算内先交再改	催交；有多次提交则零分后改
具身实验介质	钥匙则开、开门后穿过、仪器对样品、给人用 PUT
读数选题	science_note_measurement: oldest / outlier / contaminated
科学程序写出指定文件	science_run_program; 缺包改写现成栈
Windows 主机环境	直接调 Python, 不依赖 Git Bash 才能跑科学程序

Harness 循环另外保留：未花掉的预算不挡催交；提交前若轨迹显示再抽样无交集或判定过半垃圾，从 crawl 拿掉并标 decoy。

三方测题对照

测的是方法切面，不是场景脚本。分数取自 results/three-way/20260904-capability/summary.json。

题	测的能力	Harness	原版 Pi	融合 Pi
verify_solutions	便宜分叉探针，预算内提交	1.0000	1.0000	1.0000
clinical_signal	未核字段须核查或声明（硬门）	1.0000	1.0000	1.0000
corpus_dedup	经验去重 / 防泄漏，可按反馈改交	1.0000	0.7055	1.0000
treatment_response	不用泄漏或禁列	1.0067	1.0067	1.0067
corpus_procurement	经验 decoy + 陈述的垃圾上限硬门	0.8000	0.9600	0.9000
五题均分	—	0.9613	0.9344	0.9813

treatment_response 允许超过 1.0：1.0 表示打平「全部合法列」基线，再去掉无信号列会略高。

去重题 原版 0.7055，Harness 与融合都是 1.0000——Harness 的「经验重复 / 按反馈改交」进融合后保住了。

采购题 先前融合和 Harness 都是 0，因为交卷摊平读到空 plan。对齐包装后三方都过硬门、都拿到全部 oracle 高价值 token。剩下分差是 decoy F1 和区间，不是空计划。

	硬门	oracle token	decoy F1	区间盖住 133	分
原版 Pi	过	全部	0.80	是	0.96
融合 Pi	过	全部	0.50	是	0.90
Harness	过	全部	0.50	否 (lo=140)	0.80

融合五题均分最高 (0.9813)：去重跟住 Harness 的 1.0，采购跟住原版同一量级。原版被去重 0.7055 拉低，Harness 被采购 0.80 拉低。

原版留下研究合同和「按 brief 逐步探测再嵌套交卷」；Harness 留下经验硬门、交卷 schema、具身实验介质和科学程序必须写出指定文件。融合是同一个 agent 同时用两边，不是两个环。